

	Research Objective	Research Question	Main Findings	Limitations	Key Ideas to Learn	Relevance to My Thesis	summary
On the Use of Financial Data as a Random Beacon	金融市场数据(尤其是股票收盘价)能否作为公共随机源(Random beacon)使用? 作者关注的背景是密码学应用, 例如: 电子投票审计 / cryptographic protocols / public randomness generation 这些系统需要一种 公开、可验证、且难以预测的随机值。 传统随机源的问题包括: 不透明(内部 RNG)/ 不可验证(无法证明没有作弊)/ 参与者可能操控 因此作者提出一个想法: 利用金融市场这种公开、全球可观察的数据作为随机源。 金融市场具有两个吸引人的特性: 公开性(public verifiability): 所有人都能获得相同的数据。复杂性/ 与不可预测性(market uncertainty): 股票价格受大量因素影响, 理论上难以被单个参与者控制。 论文试图回答的关键问题是: 这些价格波动到底包含多少真实随机性?	1 股票价格中包含多少随机信息(entropy)? 如果价格变化几乎可以预测, 那么它不能作为随机源。作者通过建模和模拟估计: 单只股票每天能产生多少 entropy / 多只股票组合后能产生多少 entropy 2 股票之间的相关性会不会破坏随机性? 金融资产相关性高度相关, 那么组合后的随机性会被削弱。论文分析了资产之间的 mutual information 3 如何把这种“结构化金融数据”转换为密码学可用随机数? 股票本身并不是均匀随机源。论文提出一种 random beacon 方案: 从金融数据提取 seed → 使用 randomness extractor → 输出可验证随机 entropy 这种系统具有: 公共可验证性 / 难以预测 / 不依赖单一机构	1 单只股票每天大约提供 6-9 bits 的 entropy 这说明: 股票价格确实包含随机性, 但并不非常高。股票价格不是完全不可预测的, 但也不算是完美随机源。 - 这一结论很重要, 因为它给出了一个 量化估计。 2 组合股票可以显著增加 entropy 虽然单只股票 entropy 不高, 但组合资产可以累积 entropy 例如: 一个包含数百只股票的多只股票可以形成一个 entropy pool 论文估计: DJIA 的 30 只股票大约可以提供 接近 200 bits 的 entropy 这已经足以支持一些密码学用途。 3 股票之间的相关性不会完全破坏 entropy 相关性存在, 但研究发现: 相关性带来的 entropy 损失并没有想象中严重。组合资产后仍能保持较高的随机性。 4 金融数据可以作为公共随机信标的 entropy source 论文提出一种随机信标架构: 使用股票价格作为 entropy source → 通过 randomness extraction → 生成可验证随机 seed 这种系统具有: 公共可验证性 / 难以预测 / 不依赖单一机构 作者认为这种机制适用于: cryptographic protocols / election auditing / public randomness services	1 金融模型过于简化 使用 Black-Scholes / GBM 模型, 而真实市场有 fat tails, 跳跃和波动聚集等特征。 因此, 拟合统计结果高度依赖模型假设。 2 entropy 估计依赖模型假设 结果主要来自模型模拟, 而非完全数据驱动的 entropy 估计。如果模型不准确, entropy 估计可能偏差较大。 更现代的研究通常使用 non-parametric entropy estimation / information-theoretic methods 3 多资产相关性分析不足 论文只研究了单资产和双资产, 对于几十只股票的组合, 只给出粗略估计。 高维依赖结构并没有被系统建模。 4 市场操纵风险没有严格分析 论文论证: 操纵大型股票价格的成本很高, 但有可能通过 内幕消息 / 攻击成本分析 / adversarial framework 因此安全性讨论主要是定性的。 5 只研究 daily closing price 这意味着 时间分辨率很低, 信息利用不充分。 现代市场数据包含: 高频机内数据 / order book / multi-exchange price feeds 这些都可能产生更多的 entropy	1 将金融市场视为 entropy source 2 区分多层次的随机性 表面随机, 价格看起来波动。 统计随机: 从概率分布角度具有 entropy。 对攻击者不可预测: 即使有人试图预测或操纵, 也难以控制。 论文指出: 真实世界的数据通常不是均匀随机。 因此必须: source → extractor → random output 4 组合 entropy source 单个来源性 entropy 不够 通过组合多个来源可以形成 entropy pool	financial data / statistical model / entropy estimation / aggregation / randomness extraction / random beacon 这篇论文表明, 虽然单个股票价格仅包含有限的随机信息, 但通过聚合多个资产并結合随机性提取技术, 金融市场数据可以作为一种公开、可验证的随机信息来源。然而, 该方法依赖简化的金融模型并缺乏对资产相关性和市场操纵风险的深入分析。因此, 需要进一步研究以评估其在现实环境中的可靠性。	
	Random Number Generation Based on Cryptocurrency Prices and Linear Feedback Shift Register	探索 金融市场数据(尤其是加密货币价格)是否可以作为随机数生成器的外部熵源。 作者希望解决的问题是: 传统 PRNG(伪随机数生成器) 速度快但不可预测 TRNG(真随机数生成器) 需要专门硬件 是否存在一种 软件实现但仍难以预测的随机数生成方式? 提出一种 URNG(Unpredictable Random Number Generator) 核心思路: 利用加密货币价格波动作为外部熵源, 扰动一个 LFSR 伪随机数生成器, 从而提供输出序列的不可预测性。 研究重点不是金融市场本身, 而是: 现实世界的时间序列能否为随机数生成提供可利用的熵。	1 加密货币价格是否具有可利用的随机性? - 价格序列或收益率序列是否具有接近随机分布的特征 - 是否可以从中提取 bit-level 信息 作者通过分析 BTC, ETH 的价格与收益率分布进行验证。 2 如何从金融时间序列中提取随机 bit? 论文提出几种方法, 例如: 价格最低有效位 (LSB) / 收益率正负号 / 收益率与平均值之比 / 收益率分位区间 这些方法将连续时间序列转换为 0 / 1 序列。 3 这些 bit 能否提高随机数生成器的质量? 作者通过设计 LFSR + 外部扰动采样机制 来测试。如果某采样周期由市场数据决定, 是否可以增强随机性? 最终通过 Diehard randomness tests 验证结果	1 加密货币价格具有一定随机性 BTC 与 ETH 的收益率分布: 大数据均值对称 / 类似随机游走过程 数据似乎可以从中抽取随机数, 但稳定性 例如 USDC / USDT 由于波动极小, 不适合作为随机源 2 市场数据可以作为 URNG 的熵源 提出的方法是: 利用市场数据扰动 LFSR 的采样间隔, 而不是连续输出市场数据。 效果: 市场波动 → 改变采样周期 → 打乱 LFSR 输出结构 3 LFSR 长度非常重要 - 32-bit LFSR 随机性不足 - 40-bit LFSR 明显改善 → 价格 LSB 或收益率阈值方法都能通过多数随机性测试 4 简单方法已经够用 论文发现, 最简单的两种方法已经足够好: - 价格最低有效位 - 收益率 > 平均值 复杂方法并未带来明显优势。	1 随机性测试不够全面 使用 Diehard test suite 没有用 NIST SP800-22 / TestU01 2 熵量没有严格分析 没有计算 Shannon entropy / Min-entropy / entropy rate 因此无法严格证明安全性 结论更多是 经验性的统计结果 3 数据集较单一 主要使用 BTC, ETH 但没有考虑 资产组合 不同市场 不同时间尺度 4 对市场操纵问题讨论不足 金融市场不是完全随机系统。 例如: 大资金交易 市场操纵 流动性变化 这些都可能影响随机性。 5 提取数据较简单 论文只尝试了几种简单规则: LSB / threshold 没有研究: entropy extraction hash-based extraction aggregation	1 现实世界数据可以作为随机数生成的熵源, 即 可以来自复杂系统产生的不可预测行为 例如: 加密货币价格 网络流量 系统事件 2 金融时间序列本身是直接随机数, 而是熵源 论文没有直接输出市场数据, 而是: 市场数据 → 扰动 PRNG 3 收益率比价格更适合分析随机性 价格: 有趋势 非平稳 收益率: 更接近稳定分布 更适合做统计分析 4 随机性可以通过结构讨论增强 金融数据本身不一定完全随机, 但通过 aggregation / sampling perturbation / extraction 可以放大随机性	1 它证明加密货币价格波动中确实存在可用随机性 2 它提供了一个 baseline 方法: LFSR + cryptocurrency price perturbation 3 能支持的 research question: aggregation algorithms 能否提取统计级随机序列? 这篇论文已经说明: 单一资产数据 + 简单提取 + 有一定随机性, 可以进一步研究: 多资产 aggregation 是否可以提升随机性质量
Randomness beacons from financial data in the presence of an active attacker	金融市场价格是否可以作为公共随机信标(Randomness beacon)使用, 并在存在主动攻击者的情况下仍能保持安全性。 传统研究通常只分析金融数据是否具有足够的随机性(entropy), 但往往假设攻击者只能被动观察市场, 而不能主动操纵价格。本文的目标是突破这一假设, 分析一种更现实的场景: - 攻击者可以在市场上交易 - 试图通过操纵资产价格影响最终随机输出 - 从而在伪随机数生成的系统(例如彩票、区块链、密码协议)中获利 因此, 这篇文章的核心目标不是单纯研究“随机性”, 而是研究: 在主动攻击模型下, 金融数据驱动的随机信标是否仍然安全。	1 如果攻击者可以以交易为市场资产, 他是否能够操纵金融价格, 从而改变随机信标的输出? 2 引入 Verifiable Delay Function (VDF) 是否能够降低这种操纵攻击的可能性? 3 如果攻击者尝试操纵市场, 使价格达到某个预先计算的目标状态, 需要付出多大的经济成本? 文章真正研究的是: 在现实金融市场中, 操纵价格以控制随机信标输出是否存在经济上可行?	1 VDF 能有效阻止 adaptive manipulation 如果没有 VDF, 攻击者可以在最后时刻观察市场价格, 并选择最佳交易价格, 从而操纵随机信标输出。 引入 VDF 后, 攻击者必须提前很长时间预先计算可能的输出, 无法在最后时刻随意地选择攻击策略。 在现实市场中操纵大量资产的价格来控制随机信标的成本极高 基于 S&P 100 股票数据模拟 平均成本: 资本需求 200 亿美元, 潜在损失 8300 万美元; 即使拥有: 最差情况成本 68 亿美元 + 430 万损失 即使在偏向攻击者的假设下, 攻击依然困难 即使价格操纵 / 假攻击者能在最后时刻集中交易中 / 使用较优的价格冲击参数 → 依旧损失如 2	1 价格冲击使用 Brownian Motion 模型, 而非更复杂的金融市场模型。 因此: 未考虑跳跃过程 / 未考虑复杂市场微观结构 / 未考虑极端市场环境 2 价格冲击使用 square-root price impact law 估计操纵成本。 这种模型来自经验研究, 并不是严格的市场微观结构模型。因此结果可能存在误差 3 收益定价机制没有完全建模 股票收益定价通常来自 closing auction, 而不是连续交易 该机制可能会: 增加操纵难度 / 改变交易成本 → 论文没有完全建模这一过程 4 未分析攻击收益 论文主要分析攻击成本, 但没有分析 攻击收益 攻击者收益函数攻击是否经济理性。因此安全性评估并不完善。	1 Randomness + Economic Security 随机信标不需要完全不可操纵, 只需要 操纵成本远大于攻击收益。因此安全性变成 一个 经济问题。 2 VDF 作为防止适应性攻击的工具 作用是引入计算延迟, 使攻击者无法在最后时刻尝试多个操纵方案 3 将安全问题转化为市场操纵成本问题 论文把安全问题分解为两个可计算问题: - 通过 aggregation 或类似转换方法, 把价格目标映射回目标状态 - 需要多少资金 层次一: 统计随机性 → 研究聚合算法如何提高准确, 通过哪些 tests。 层次二: 对抗鲁棒性 → 研究如果有人在试图影响输入价格, 这个方案会不会失效, 或者失败成本有多高。	1 它证明加密货币价格波动中确实存在可用随机性 2 提供分析随机信标安全性的框架 论文给出了一个完整的分析思路: 使用金融数据作为 entropy source → 使用 extractor 处理价格数据 → 使用 VDF 防止 adaptive manipulation → 估计市场操纵成本 这一框架可以作为 thesis 的 理论背景 3 将安全性与成本联系起来 需要通过 aggregation 或其他转换方法, 来减少这些结构性影响。	若把大盘股票价格作为公共随机数来源, 在存在主动市场操纵时是否仍然安全。作者提出的关键思路是: 先用资产价格作为熵源, 再通过 VDF 引入时间延迟, 迫使攻击者提前计算输出结果, 而不能在最后时刻随意操纵价格来选择操纵策略。随后, 作者把安全性转化为一个金融经济问题: 市场使用 VDF 延迟期间自然数成本有多高, 以及把它重新预测目标价格需要多大资本与滑点成本。
	Empirical properties of asset returns: stylized facts and statistical issues	研究股票市场价格订单簿 limit order book 的统计性质 理解: 市场参与者如何提交限价订单 订单簿在统计意义上有什么结构 是否可以用简单模型解释价格形成机制 论文的核心思想是: 股票价格波动来源于订单流(order flow)和订单簿结构的相互作用, 而不是纯粹随机过程。	1 限价单价格距离从幂律分布 新提交的限价单与当前最优价格之间的距离呈 power law distribution 这意味着: 很多订单会挂在 非常远的价格 分布尾部非常长 直置解释: 交易者认为 大幅价格波动是可能的, 因此会挂远距离订单等待极端行情 2 平均订单簿呈 “hump shape” 时间平均后的订单簿形状如下: 在 best bid / ask 附近反而较低, 在稍远处达到最大值, 然后逐渐下降 原因: 两个机制竞争: 订单流入 越靠近当前价格 → 新订单越多 订单成交 越靠近当前价格 → 更容易被吃掉 因此, 最优价附近订单 存活时间越长, 这一点位置 更容易积累最终形成 hump 结构。 3 最优价位单数量服从 Gamma 分布 bid 和 ask 最优价位上的挂单量: 近似 Gamma distribution 说明: 订单簿局部流动性波动大 / 小规模挂单更常见 4 Zero-intelligence 模型可以解释这些统计规律 作者提出一个简单模型: 限价单随机到达 / 市场单随机成交 / 挂单随机取消 即使不假设复杂交易策略, 这个模型也能重现 hump-shaped order book + bidask volume distribution → 一些短期价格特征说明很多市场统计规律可能来自基本随机机制, 而不一定需要复杂性行为。 1 超高频价格方向通常不是完全随机的。 在 tick-level 数据中, 价格方向序列性拒绝独立性假设, 说明短期内存在统计上的可预测结构。 2 聚合会显著降低可预测性。 当价格按照 transaction time 进行聚合(例如每 10 或 15 笔交易聚合一次价格)时, 随机性显著增强, 越来越多的交易日无法拒绝“随机序列”的假设。 3 可预测性与市场流动性相关。 在低预期的交易日中, 通常观察到更高的交易量、更多非零收益以及更强的收益自相关。 4 可预测性有两种不同模式。 对于一些资产, 可预测性来自方向持续性(price persistence); 而对于另一些资产, 可预测性来自频率的方向反转(alternating patterns)。 5 可预测性通常是局部时间尺度现象。 在很多情况下, 统计显著的可预测性只出现在某些特定时间窗口, 而不是贯穿整个交易日。	1 数据仅包含 三只股票和一个月样本, 普适性需要更多市场验证。 2 订单簿数据中缺少完整的订单修改和撤单记录, 因此订单簿需要重建, 可能带来误差。 3 研究主要集中在 静态订单簿统计性质, 没有深入分析动态价格影响和长期市场行为。 4 虽然发现了限价单距离的幂律分布, 但论文没有给出其统计学或行为学解释。	1 股票价格波动来源于订单簿微观结构, 而不是完全随机金融。 2 高频金融数据具有稳定统计规律, 例如 power law order placement and hump-shaped liquidity distribution. 3 简单机制也可以产生复杂统计结构, 市场现象不一定需要复杂性模型才能解释。	1 论文表明, 高频金融市场价格并不是完全随机的, 而是包含明显的统计结构。 2 订单提交行为和订单簿结构会影响价格变化, 因此价格序列可能带有结构性偏差。 3 如果将金融数据用于随机数生成, 需要通过 aggregation 或其他转换方法, 来减少这些结构性影响。	本文研究高频金融价格序列是否具有统计意义上的随机性。作者提出了一种基于信息论(Shannon entropy 与 KL divergence)的随机性检验方法, 用来判断价格方向序列是否独立于历史信息。进一步地, 文章分析交易时间(transaction time)聚合对价格随机性的影响, 并探讨在什么情况下市场表现出可预测性。
Price predictability at ultra-high frequency: Entropy-based randomness test	本文的目标是研究超高频金融价格序列是否具有统计意义上的随机性。作者提出一种基于信息论(Shannon entropy 与 KL divergence)的随机性检验方法, 用来判断价格方向序列是否独立于历史信息。进一步地, 文章分析交易时间(transaction time)聚合对价格随机性的影响, 并探讨在什么情况下市场表现出可预测性。	1 如果价格序列存在可预测性, 这种可预测性是由什么统计结构导致的? 2 平均订单簿有什么样子? 3 订单簿统计结构是否可以由简单模型解释? zero-intelligence model 4 可预测性是否在整个交易日均存在, 还是只是在某些时间区间?	1 超高频价格方向通常不是完全随机的。 在 tick-level 数据中, 价格方向序列性拒绝独立性假设, 说明短期内存在统计上的可预测结构。 2 聚合会显著降低可预测性。 当价格按照 transaction time 进行聚合(例如每 10 或 15 笔交易聚合一次价格)时, 随机性显著增强, 越来越多的交易日无法拒绝“随机序列”的假设。 3 可预测性与市场流动性相关。 在低预期的交易日中, 通常观察到更高的交易量、更多非零收益以及更强的收益自相关。 4 可预测性有两种不同模式。 对于一些资产, 可预测性来自方向持续性(price persistence); 而对于另一些资产, 可预测性来自频率的方向反转(alternating patterns)。 5 可预测性通常是局部时间尺度现象。 在很多情况下, 统计显著的可预测性只出现在某些特定时间窗口, 而不是贯穿整个交易日。	1 只研究价格方向而非非收益维度。 价格离散化作为 上涨/下跌 符号, 这种处理忽略了收益率大小信息。 2 统计检验依赖较长序列。 方法基于 tick-level 分析, 需要较长的时间序列才能稳定工作。 3 没有考虑交易成本。 即使检测到可预测性, 也不能直接说明存在可盈利交易策略。 4 仅研究一种聚合方式。 文章主要分析 transaction-time aggregation, 其他聚合方式(如 calendar time 或 volume time)未做系统研究。	1 使用信息论方法检测随机性。 通过 entropy 与 KL divergence 可以构建统计检验来判断时间序列是否独立随机。 2 金融时间序列的随机性具有“尺度依赖性”。 在不同时间尺度(tick, aggregated level)下, 序列的随机性特征可能发生变化。 3 聚合可以改变序列结构。 Aggregation 可能短期削弱长期依赖结构, 使序列更接近随机过程。 4 可预测性不一定意味着趋势。 可预测性既可能来自趋势持续, 也可能来自系统性的反转模式。	1 证明了原始高频金融数据并非完全随机, 这说明在超高频价格数据作为随机源时必须谨慎。 2 aggregation 可以增加随机性 3 entropy-based randomness test 为评估价格序列随机性提供了方法学框架, 可作为后续随机性评估的参考 4 支持金融数据作为随机源的可能性	本文研究超高频金融价格序列是否具有统计意义上的随机性。作者提出了一种基于信息论的随机性检验方法, 通过 Shannon 熵和 KL 散度来检验价格方向序列是否独立。实证结果表明, 在 tick 级别下价格方向通常存在短期可预测性, 但随着交易时间聚合程度增加, 这种可预测性显著下降。研究说明金融价格的随机性具有明显的尺度依赖性, 而聚合处理可能使价格序列更接近随机过程。
	Emergence of Randomness in Temporally Aggregated Financial Tick Sequences	探讨: 当高频金融价格数据经过时间聚合(temporal aggregation)后, 随机性如何逐渐“涌现”(emerge) 与传统金融研究侧重预测性或市场效率不同, 作者采用了一种更关注熵增和随机性生成机制的方法: 将价格变动转换为 二进制序列(0/1) 使用 标准随机性测试工具(NIST STS, TestU01 等) 评估这些序列在不同聚合层级下的随机性程度 最终目标是回答一个更广泛的问题: 金融市场数据是否可以作为一种潜在的随机信标来源(entropy source)	1 原始高频 tick 价格序列是否具有随机性? 即: 如果直接将逐笔交易价格序列的随机性? 是否随着 aggregation level 增加 金融序列会越来越像真正的随机序列? 3 在什么聚合层级下, 金融数据可以通过标准随机性测试? 需要多大程度的聚合, 金融数据才会“看起来像随机数”。	1 随机性会随聚合层级增加而增强 在原始 tick 数据层面, 价格变化存在明显趋势和可预测性。但随着 aggregation level 增加, 这些特征逐渐被“平均掉”, 序列变得更像随机序列。 作者称这种现象为: whitening effect(漂白效应) 2 随机性的提升并不是简单的 在某些随机性测试中, 作者观察到: 随机性可能先下降再上升 这种现象可能源于 幂律分布与复杂市场微观结构 有关。 3 不同资产之间差异明显 例如: AAPL 和 TSLA 等交易极其活跃的股票, 即使在高 aggregation level 下 仍然表现出一定可预测性。说明: 交易活跃度低, 微观结构复杂, 随机性涌现可能较慢。 4 经过适当聚合后, 金融数据可以通过随机性测试 在较高 aggregation level 下 许多资产生成的二进制序列能够通过: NIST STS / TestU01 等标准随机性测试。 这意味着: 金融市场数据可能成为一种潜在的随机数来源。	1 只使用价格方向信息 作者只使用“涨 / 跌”方向构造二进制序列, 忽略了价格变化幅度。 因此: 部分潜在信息被丢失。 2 数据样本有限 研究只使用: 约 80 个交易日 9 个资产 这个窗口未必能代表市、场、股、债波动时期或不同市场环境下的普遍规律。因此结论的普适性仍然有限。 3 部分随机性测试依赖 0/1 平衡 某些测试假设 0 和 1 出现概率接近 50% 但金融数据中 上涨与下跌未必均衡。 因此: 测试失败可能源于 概率偏差而非时间依赖。 !! 该问题在论文中被识别并通过阈值函数方法部分缓解 !! 可以被认为是局限: 这种修正不是在线方法: 改变了原始金融数据结构 是人为重新编码数据。 4 随机性具有尺度依赖性 金融数据在不同时间尺度下表现不同: tick level → 非随机 higher aggregation → 更随机 因此 随机性并不是固定属性, 而是尺度相关属性。	1 验证了 aggregation 增强随机性的现象 2 提供了一套完整实验方法 可以直接借鉴: 价格数据 → 二进制编码 → aggregation → 随机性测试(NIST / TestU01) 3 揭示了一些关键问题 如果价格序列在聚合后变得更随机, 则: 高频统计检验失败 / 重复测试 / 序列下降 / 价格接近理论最大值 因此, compression-based entropy estimation 可以作为一种传统随机性检验(如 NIST tests)的补充方法, 用于衡量金融时间序列在不同聚合层级下的随机性变化。 此外, 论文提出的 compression-based distance 也可用于比较: 不同时间尺度的价格序列 / 不同资产市场的数据 / 聚合前后序列生成机制的差异 从而为研究 aggregation 如何改变时间序列结构 提供新的分析工具 提供了一种衡量金融时间序列随机性的方法框架: 通过构造已知统计结构后, 再计算 entropy 来评估价格序列是否接近随机过程。这一思路与论文主题“从金融时间序列中提取随机性用于随机数生成”直接相关, 因为它探讨了如何区分真正的随机性是由市场结构产生的可预测模式。	金融 tick 数据的非随机性主要体现在超高频微观结构上, 而时间聚合会在很大程度上把这种“噪音”过滤掉, 使序列的二进制序列, 但在这种涌现过程中, 高频统计检验失败 / 重复测试 / 序列下降 / 价格接近理论最大值 / 测试方法会严重影响结论。这些问题可以成为 thesis 中进一步研究的方向
Language Trees and Zipping	很适合作为论文论题的 motivation 或 methodology discussion 作者的核心目标是验证: 压缩算法是否可以作为信息论测量工具来生成序列的数值描述长度 论文问题: 实际压缩算法 如 LZ77 是否可以作为 Kolmogorov entropy 的可计算近似? 如果一个问题已经被证明为不可解, 那么它是否可以用压缩算法来近似? 同时作者指出, 这种方法并非不文本本, 也适用于 DNA 序列和时间序列(包括金融数据) --- 来验证	1 是否可以仅依赖压缩算法来比较序列结构? 传统方法需要: 语言模型 / 语法结构 / 概率分布估计 作者提出: 是否可以在不知道序列统计模型的情况下, 仅通过压缩率来近似序列结构? 2 压缩长度能近似序列的病? 信息论中: 衡量序列的不确定性 / Kolmogorov complexity 衡量生成序列的数值描述长度 论文问题: 实际压缩算法 如 LZ77 是否可以作为 Kolmogorov entropy 的可计算近似? 3 是否可以利用压缩算法来近似序列的“距离”? 如果一个压缩器已经对 A 序列进行了统计模式: 用它压缩来自 B 的序列 / 压缩效率会下降 问题: 这种 压缩效率差异 能否估计两个序列生成机制之间的 relative entropy?	1 压缩率可以近似估计序列熵 对于来自遍历系统 ergodic source 的长序列: LZ77 压缩后的长度比例会收敛到序列的熵 entropy rate 因此, 压缩率可以作为 序列信息量的近似度量 2 可以利用压缩量估计 relative entropy 论文提出一个核心思路: 先对 A 序列 A 让压缩算法学习其统计结构, 再将来自 B 序列 B 的短片段拼接并压缩。如果该片段在这种压缩模型下压缩效果较差, 说明 B 的统计结构与 A 不同, (因为压缩长度的增加)可以作为一个序列生成机制差异(relative entropy)的近似度量。 3 压缩距离可以用于分类任务 研究发现莫斯科证券交易所 在大多数时期并不完全有效: 约 80% 的月份被判定为存在市场低效率, 即价格序列显著偏离完美随机性。部分股票在特定时期出现连续几小时方向波动的模式, 说明短期价格存在可预测性。	1 实验主要针对于干文本 虽然论文指出方法适用于时间序列和金融数据, 但所有实验都是语言任务, 因此在金融数据上的有效性仍需验证 2 必须将数据离散化 压缩算法处理的是符号序列, 因此: 连续数值数据(如价格)必须离散化为离散符号, 例如: 上涨 / 下跌 / 多次收益分类 / quantization 不同离散方式会显著影响压缩率 3 序列长度选择敏感 测试片段 必须较短 如果片段过长, 压缩器会在片段内部重新学习统计结构, 导致测试不再反映两个序列之间的差异 4 压缩距离只是 relative entropy 的近似 估计结果依赖: 压缩算法 / 数据长度 / 序列结构 因此不是严格的 KL divergence 估计	1 压缩算法是一种信息论工具 压缩不仅只是工程技术, 还可以作为 序列熵率的可靠近似 2 随机性与可压缩性密切相关 如果序列存在重复模式 / 存在统计依赖 / 可预测, 则压缩率较低 如果序列接近随机, 则 几乎不可压缩 / 压缩率接近 1 3 可以通过压缩 比较序列生成机制 压缩序列到的统计结构, 可以作为序列的 隐式模型, 比较压缩结果, 就可以比较两个序列的生成机制差异。 4 不需要显式统计模型 该方法是完全非参数的, 无需概率分布假设 / 马尔可夫模型 / 语言模型, 因为压缩器可以自动学习模式 金融时间序列中的随机性可以用 Shannon entropy 来量化, 但在计算之前需要先过滤掉一些“伪随机结构”(如波动率聚集、价格停滞、日内季节性等), 否则会把把这些统计规律当成市场 inefficiency。	1 验证了 aggregation 增强随机性的现象 2 提供了一套完整实验方法 可以直接借鉴: 价格数据 → 二进制编码 → aggregation → 随机性测试(NIST / TestU01) 3 揭示了一些关键问题 如果价格序列在聚合后变得更随机, 则: 高频统计检验失败 / 重复测试 / 序列下降 / 价格接近理论最大值 因此, compression-based entropy estimation 可以作为一种传统随机性检验(如 NIST tests)的补充方法, 用于衡量金融时间序列在不同聚合层级下的随机性变化。 此外, 论文提出的 compression-based distance 也可用于比较: 不同时间尺度的价格序列 / 不同资产市场的数据 / 聚合前后序列生成机制的差异 从而为研究 aggregation 如何改变时间序列结构 提供新的分析工具 提供了一种衡量金融时间序列随机性的方法框架: 通过构造已知统计结构后, 再计算 entropy 来评估价格序列是否接近随机过程。这一思路与论文主题“从金融时间序列中提取随机性用于随机数生成”直接相关, 因为它探讨了如何区分真正的随机性是由市场结构产生的可预测模式。	这篇论文探讨了如何通过压缩算法来近似序列的熵率, 并验证了压缩算法是否可以作为信息论测量工具来生成序列的数值描述长度。论文问题: 实际压缩算法 如 LZ77 是否可以作为 Kolmogorov entropy 的可计算近似? 如果一个问题已经被证明为不可解, 那么它是否可以用压缩算法来近似? 同时作者指出, 这种方法并非不文本本, 也适用于 DNA 序列和时间序列(包括金融数据) --- 来验证
Efficiency of the Moscow Stock Exchange before 2022	研究俄罗斯莫斯科证券交易所(2012-2021)的市场效率程度。通过高频股票收益序列计算 Shannon entropy 来衡量价格随机性, 并识别市场是否偏离有效市场假说。	股票价格序列在过度偏离统计规律(如波动率聚集、价格停滞等)之后, 是否仍会表现出明显的可预测性? 如果是, 这种偏离随机性的程度有多大?	研究发现莫斯科证券交易所 在大多数时期并不完全有效: 约 80% 的月份被判定为存在市场低效率, 即价格序列显著偏离完美随机性。部分股票在特定时期出现连续几小时方向波动的模式, 说明短期价格存在可预测性。	研究发现离散化后的收益序列和 entropy 估计, 结果可能受到离散化方式和样本长度的影响; 同时, 即使检测到可预测模式, 也未必符合有效市场假说。市场摩擦等现象因素, 因此并不一定能被转换为可盈利策略。	金融时间序列中的随机性可以用 Shannon entropy 来量化, 但在计算之前需要先过滤掉一些“伪随机结构”(如波动率聚集、价格停滞、日内季节性等), 否则会把把这些统计规律当成市场 inefficiency。	1 验证了 aggregation 增强随机性的现象 2 提供了一套完整实验方法 可以直接借鉴: 价格数据 → 二进制编码 → aggregation → 随机性测试(NIST / TestU01) 3 揭示了一些关键问题 如果价格序列在聚合后变得更随机, 则: 高频统计检验失败 / 重复测试 / 序列下降 / 价格接近理论最大值 因此, compression-based entropy estimation 可以作为一种传统随机性检验(如 NIST tests)的补充方法, 用于衡量金融时间序列在不同聚合层级下的随机性变化。 此外, 论文提出的 compression-based distance 也可用于比较: 不同时间尺度的价格序列 / 不同资产市场的数据 / 聚合前后序列生成机制的差异 从而为研究 aggregation 如何改变时间序列结构 提供新的分析工具 提供了一种衡量金融时间序列随机性的方法框架: 通过构造已知统计结构后, 再计算 entropy 来评估价格序列是否接近随机过程。这一思路与论文主题“从金融时间序列中提取随机性用于随机数生成”直接相关, 因为它探讨了如何区分真正的随机性是由市场结构产生的可预测模式。	这篇论文探讨了如何通过压缩算法来近似序列的熵率, 并验证了压缩算法是否可以作为信息论测量工具来生成序列的数值描述长度。论文问题: 实际压缩算法 如 LZ77 是否可以作为 Kolmogorov entropy 的可计算近似? 如果一个问题已经被证明为不可解, 那么它是否可以用压缩算法来近似? 同时作者指出, 这种方法并非不文本本, 也适用于 DNA 序列和时间序列(包括金融数据) --- 来验证
Statistical properties of stock order books: empirical results and models	系统总结了金融市场中反复出现的一组 stylized facts (经验事实)。这些特征在股票、指数、外汇等不同资产市场中都被观察到, 因此被认为是金融时间序列的基本统计规律。 首先, 资产收益率通常表现出 几乎没有显著的线性自相关。在多数市场和不同尺度下, 收益率序列的自相关函数会迅速衰减接近零。这意味着价格变化的方向很难通过简单的线性模型预测。然而, 这一点并不意味着收益率是独立随机变量, 因为非线性依赖结构仍然存在。 其次, 收益率分布通常表现出 明显的厚尾 (heavy tails), 与正态分布相比, 金融收益率出现极端波动的概率要高得多。实证研究普遍发现收益率尾指数大约在 2 到 5 之间, 这意味着极端市场事件比传统高斯模型预测的更常见。 第三, 金融时间序列普遍存在 volatility clustering (波动率聚集), 高波动时期往往会持续一段时间, 而低波动时期也会持续出现。虽然收益率方向难以预测, 但波动水平却具有明显的时间依赖结构。 此外, 研究还发现 绝对收益率或平方收益率的自相关函数衰减非常缓慢。这种慢速衰减表明金融时间序列中存在显著的非线性依赖关系。股票市场中还经常观察到 leverage effect, 即负收益率往往会带来未来波动率上升。 这些现象共同说明, 虽然金融收益率在均值层面看起来接近随机, 但其分布形态和波动结构仍然具有复杂的统计特征。	进一步讨论了这些 stylized facts 对统计建模和数据分析带来的重要影响。传统金融模型通常假设收益率服从正态分布并满足独立同分布 (IID) 假设, 但实际数据显著偏离这些条件。 首先, 厚尾分布会导致许多统计量变得不稳定, 在 heavy-tailed 数据中, 收益率分布的推断方法可能并不坚实。 其次, 金融数据通常样本规模有限, 而复杂的依赖结构会进一步降低估计统计的稳定性。在这种情况下, 许多经典统计方法传统的收敛定理可能并不适用。 文章还指出, 金融时间序列在统计上可能面临 stationarity and ergodicity 问题。如果数据的统计性质随时间变化, 那么通过时间平均得到的统计量可能无法代表真实分布。 此外, 市场参与者还在明显的 非线性依赖结构, 虽然收益率本身缺乏显著自相关, 但对收益率和波动率指标却表现出强烈的时间相关性。这表明金融数据的随机性远比简单白噪声过程复杂。 这些统计问题提醒, 在分析金融数据时需谨慎使用传统统计方法, 并充分考虑数据本身的特殊性质。	文章讨论时间尺度在金融时间序列中的重要作用。一个关键发现是 aggregation 会显著改变收益率的统计性质。 实证研究表明, 当时间尺度增加时 (例如从分钟数据切换到日线), 收益率分布会迅速接近正态分布。这一现象被称为 aggregation Gaussianity, 高频数据通常表现出明显的尖峰厚尾结构, 而较低频率的收益率分布则更加平滑。 这一现象说明时间尺度本身是金融数据分析中的关键因素, 不同时间尺度下的收益率可能呈现出不同的统计特性。因此时间聚合不仅仅只是数据处理步骤, 而是会实质性改变数据的统计特征。 从更广泛的角度看, 这一结果表明 aggregation 可能在一定程度上削弱时间序列中的高频特征, 使得收益率分布在较大时间尺度上更接近传统统计模型假设。	重要的理论背景意义。 首先, 这篇文章表明金融收益率并不是理想的随机序列, 虽然收益率通常缺乏显著的线性自相关, 但仍然存在厚尾分布、波动率聚集以及非线性依赖结构。因此, 金融数据不能被简单地视为天然的随机数来源。 其次, 文章关于 aggregation 改变收益率统计性质的讨论为我的研究提供了重要启发。随着时间尺度增加, 收益率分布会逐渐接近高斯分布, 这表明 aggregation 可能在一定程度上平滑掉原始序列中的结构性特征。 然而, 这种平滑变化并不意味着数据已经变得完全随机, 即使分布更加接近正态, 波动率聚集和其他依赖结构仍可能存在。因此, 在利用金融数据作为随机源时, 仍然需要通过随机性检验和综合分析来评估其质量。 此外, 这篇文章还提醒我们, 在评估金融数据随机性时不能仅依赖简单统计指标, 例如, 收益率缺乏线性自相关并不意味着数据完全随机, 因为非线性依赖结构仍然可能隐藏在数据中。因此, 在 my thesis 中, 我需要结合各种随机性检验方法来评估 aggregation 后序列的统计性质。	正态分布是最大熵分布(在给定的均值和方差下), 当分布趋近于正态时, 意味着随时间间隔增加, 那些细粒的、微观的结构性依赖(如波动率聚集、价格停滞、日内季节性等), 剩下的, 是更接近纯粹随机源的成分。 因此, 聚合过程可以		